

Estimer l’opinion d’un sous-groupe sur une question inédite

Premiers résultats · Llama 3.3 70B fine-tuné · 12 questions, 275 sous-groupes

Hubert Cadieux · Septembre 2026

En bref. Ce premier test vérifie si un modèle de langage peut reproduire la répartition des réponses d’un sous-groupe sociodémographique à une question de sondage qu’il n’a jamais vue.

- **L’entraînement sur des réponses de sondage fonctionne.** Le modèle entraîné divise par 2,5 la distance aux vrais répondants et s’approche d’un plancher humain (la distance entre deux échantillons de vraies personnes).
- **Donner au modèle des indices sur le groupe n’aide pas**, du moins dans le format testé : lui montrer comment le sous-groupe a répondu à des questions voisines n’améliore pas la distance moyenne.
- **La température compte pour le modèle entraîné, presque pas pour le modèle non entraîné**, ce comme dans les tests de Justin. Une température de 1,0 est adéquate.

1. Question et design

La question

Peut-on estimer comment un sous-groupe répondrait à une **nouvelle** question de sondage, sans l’avoir posée? L’unité évaluée n’est pas la personne mais la distribution d’un groupe : par exemple, la répartition des réponses des femmes de 25 à 34 ans titulaires d’un baccalauréat à une question sur la souveraineté.

Données et partage

Sondages	17 sondages québécois et canadiens, 1998–2025, en français et en anglais
Répondants	108 199
Questions	1 778 au catalogue, dont 1 633 utilisables comme cibles d’opinion
Test	60 questions gelées avant tout entraînement ; ce premier test en évalue 12
Unités évaluées	275 couples question × sous-groupe

Un **sous-groupe** (ou cellule) croise l’âge, le genre et la scolarité, ou seulement l’âge et le genre quand les effectifs sont trop faibles.

Seules 12 des 60 questions de test sont évaluées ici, pour limiter le coût d’inférence avant d’engager toute la batterie : quatre questions dans chacun de trois thèmes (identité et fédéralisme, partis et vote, valeurs sociales), dans les deux langues. Les 48 autres restent gelées pour la suite.

Le partage est fait **par répondant**. 78 055 répondants servent à l’entraînement ; 30 144 n’y participent jamais et sont coupés en deux moitiés : 14 947 répondants de **contexte**, qui peuvent servir d’indices, et 15 197 répondants d’**évaluation**, la vérité à reproduire.

Deux modèles, cinq conditions

Deux modèles sont entraînés à partir de Llama 3.3 70B, sur les **mêmes 8 000 exemples** répondant-question, avec la réponse réelle du répondant comme cible :


- le **modèle standard** voit le profil du répondant et la question ;
- le **modèle à indices** voit en plus les réponses du même répondant à six questions voisines au plus. Il apprend ainsi à se servir d'indices sur la personne.

Le design pose deux questions : l'entraînement aide-t-il? et des indices sur le groupe aident-ils? D'où trois conditions principales et deux contrôles.

Condition	Modèle	Ce qu'il reçoit en plus du profil et de la question
Non entraîné	Llama 3.3 70B d'origine	rien
Entraîné	standard	rien
Entraîné + indices	à indices	comment le sous-groupe a répondu à six questions voisines au plus (répondants de contexte)
<i>Indices retirés</i> (contrôle)	à indices	rien ; isole l'effet de l'entraînement à indices
<i>Fuite</i> (contrôle)	à indices	les mêmes indices, calculés en incluant les répondants d'évaluation

Les indices ne contiennent jamais la question cible ni sa distribution. Chaque condition répond 100 fois par sous-groupe, à quatre températures (0,3 ; 0,7 ; 1,0 ; 1,3).

Protocole expérimental



Évaluation

Les 100 réponses d'une condition forment une distribution, comparée à celle des répondants d'évaluation du même sous-groupe par la **variation totale** : la part des réponses qu'il faudrait déplacer pour passer d'une distribution à l'autre (0 = identiques, 1 = disjointes). La moyenne est prise sur les sous-groupes de chaque question, puis sur les 12 questions. Les comparaisons entre conditions sont appariées sur les mêmes sous-groupes, avec un bootstrap sur les questions. L'analyse principale est à température 1,0.

Plancher humain. Pour situer les chiffres, la même distance est calculée entre les répondants de contexte et ceux d'évaluation, sous-groupe par sous-groupe : deux échantillons de vraies personnes du même profil. Avec environ 40 répondants par moitié, ce plancher est élevé. Il est aussi un peu pessimiste, puisqu'il additionne le bruit de deux échantillons.

La métrique (variation totale plutôt que KL) et le niveau d'évaluation (sous-groupe plutôt que distribution nationale) diffèrent de ceux de Justin : les niveaux absolus ne se comparent pas directement aux siens.

2. Résultats

L'entraînement rapproche le modèle du plancher humain

Condition	Variation totale	IC 95 %	Écart au plancher humain
Humain (plancher)	0,186	[0,153 ; 0,222]	—
Entraîné	0,219	[0,186 ; 0,257]	+0,033 [0,014 ; 0,051]
Entraîné + indices	0,246	[0,202 ; 0,288]	+0,059 [0,025 ; 0,097]
<i>Indices retirés</i>	0,242	[0,203 ; 0,283]	+0,056 [0,014 ; 0,100]
<i>Fuite</i>	0,240	[0,195 ; 0,290]	+0,054 [0,013 ; 0,099]
Non entraîné	0,548	[0,478 ; 0,616]	+0,362 [0,304 ; 0,430]


Température 1,0 ; 12 questions, 275 sous-groupes.

Le modèle entraîné comble environ 90 % de l'écart entre le modèle non entraîné et le plancher humain. Il reste significativement au-dessus du plancher, et l'écart grandit sur les sous-groupes d'au moins 30 répondants, où le plancher est moins bruité (annexe B).

Le modèle non entraîné échoue surtout parce qu'il **répond presque toujours la même chose** : son option la plus fréquente reçoit 93 % des tirages, contre 50 % chez les vrais répondants. Le modèle entraîné retrouve la bonne dispersion (51 %). L'effondrement est plus marqué que celui du bras roleplay de Justin, autour de 54 %.

Résultats par item, température 1,0

Variation totale moyenne sur les cellules de chaque item.




Le constat tient question par question : le modèle entraîné est plus proche du plancher que du modèle non entraîné sur les 12 questions, et à moins de 0,04 du plancher sur 8 d'entre elles.

Les indices sur le groupe n'améliorent pas la distance moyenne

Comparaisons appariées, température 1,0

Différence de variation totale et IC 95 % (bootstrap apparié). Négatif = premier bras meilleur.



- **Effet des indices** (Entraîné + indices contre Indices retirés) : +0,003 [-0,038 ; 0,040]. Montrer au modèle comment

le sous-groupe a répondu à des questions voisines ne change rien en moyenne.


- **Meilleur montage** (Entraîné + indices contre Entraîné) : +0,026 [-0,005 ; 0,057]. Le montage le plus riche ne bat pas le plus simple ; à température 0,7, il est même significativement moins bon.
- **Fuite** : -0,005 [-0,024 ; 0,012]. Inclure les répondants d'évaluation dans les indices ne gonfle pas les résultats.

Deux éléments nuancent ce constat. D'abord, le modèle à indices a appris à lire les réponses **individuelles** d'une personne, alors qu'on lui donne ici des **distributions** de groupe ; ce changement de format peut l'empêcher d'en tirer parti. Ensuite, les indices ont un effet visible ailleurs : ils rétablissent les différences entre sous-groupes que le modèle entraîné aplatit de moitié (annexe D), même si ça ne se traduit pas en distance moyenne.

Selon la température

Distance aux vrais répondants selon la température

Variation totale moyenne, 12 items, 275 cellules. Plus bas = plus fidèle.



Condition	T = 0,3	T = 0,7	T = 1,0	T = 1,3
Non entraîné	0,590	0,568	0,548	0,532
Entraîné	0,366	0,239	0,219	0,220
Entraîné + indices	0,415	0,283	0,246	0,246
Indices retirés	0,369	0,266	0,242	0,243
Fuite	0,402	0,265	0,240	0,231
Humain (plancher)	0,186	0,186	0,186	0,186

Variation totale moyenne. Part de l'option la plus fréquente et contrastes par température : annexe C.

- **Les modèles entraînés dépendent fortement de la température** : à 0,3, ils concentrent trop leurs réponses (81 % sur l'option la plus fréquente pour le modèle entraîné) ; à 1,0, ils retrouvent la dispersion observée ; à 1,3, la distance ne bouge plus mais les réponses hors options apparaissent.
- **Le modèle non entraîné bouge à peine** : il reste concentré sur une option à toutes les températures.
- **Les conclusions ne dépendent pas de la température** : l'entraînement aide nettement partout, et les indices n'aident nulle part.

C'est le même contraste que Justin observait entre son fine-tune de 4 milliards de paramètres et un modèle prompté : la température agit sur un modèle entraîné, beaucoup moins sur un modèle simplement prompté. La température 0 n'a pas été testée ici.

3. Ce qu'on retient et où investir

Ce qui a marché

- Entraîner le modèle sur des réponses individuelles de sondage : c'est l'essentiel du gain, sur toutes les questions, dans les deux langues et les trois thèmes.
- Répondre par le texte de l'option (plutôt qu'un code) : les réponses restent valides sur des questions inédites.
- Le protocole : questions et répondants gelés avant l'entraînement, aucun tirage perdu, un contrôle de fuite qui confirme que l'évaluation n'est pas contaminée.

Ce qui n'a pas marché

- Les indices sur le groupe, dans le format actuel : ils ne battent pas le modèle le plus simple.
- Le modèle non entraîné, même avec un bon prompt : il donne la même réponse à tout le monde.

Où mettre l'effort, par ordre de rendement attendu

1. **Plus de questions de test.** L'incertitude sur les comparaisons vient surtout du petit nombre de questions. Les 48 questions gelées restantes ne demandent que de l'inférence, avec les modèles déjà entraînés. C'est le moyen le moins cher de rendre les conclusions solides.
2. **De plus gros sous-groupes d'évaluation.** Avec une quarantaine de répondants par sous-groupe, le bruit d'échantillonnage est presque aussi grand que l'erreur du modèle : on ne peut plus voir une amélioration. Il faut privilégier des questions tirées de grands sondages, ou des sous-groupes plus larges, plutôt que plus de répondants à l'entraînement.
3. **Plus d'exemples d'entraînement : à trancher avec les runs en cours.** 8 000 exemples, c'est peu au regard des données disponibles, mais Justin trouvait qu'entraîner plus longtemps dégradait les résultats. Les mêmes modèles, entraînés sur 20 000 exemples, répondront à la question.
4. **Les indices, avec un format cohérent.** Une seule expérience ciblée : entraîner le modèle directement avec des distributions de groupe, comme il les reçoit à l'inférence. Les indices rétablissent déjà les écarts entre groupes ; c'est la piste la plus plausible pour la question centrale du projet.

Ce qu'on peut laisser de côté

- Balayer davantage la température : 1,0 fonctionne, et 1,3 n'apporte que des réponses invalides.
- Le modèle non entraîné comme méthode : il ne sert plus que de point de comparaison.
- La crainte de fuite entre indices et évaluation : le contrôle ne montre aucun effet.

Limites. 12 questions sur 60 ; sous-groupes petits (médiane de 31 répondants d'évaluation) ; un seul modèle de base, une seule époque. Les règles d'analyse principales ont été fixées avant de consulter les résultats ; le plancher humain, prévu au protocole, a été calculé ensuite.

Annexes

A. Résultats par question (température 1,0)

Question	Lang.	Proximité	Cell.	Humain	Entraîné	E. + ind.	Ind. ret.	Non entr.
Souveraineté, langue et culture (CES 2021)	en	quasi-doublon	43	0,13	0,16	0,13	0,25	0,63
Importance de l'ethnicité et de la langue (CES 2019)	en	loin	34	0,21	0,19	0,21	0,16	0,50
Partage des dépenses fédérales (EEQ 2012)	fr	isolée	11	0,21	0,19	0,24	0,20	0,48
Plus de pouvoirs ou indépendance (EEQ 2012)	fr	proche	11	0,17	0,21	0,18	0,26	0,38
Meilleur premier ministre (CECD 1998)	fr	loin	9	0,12	0,16	0,12	0,14	0,37
Meilleur parti : immigration (EEQ 2018)	fr	modérée	8	0,17	0,24	0,34	0,32	0,67
Parti de 2 ^e choix (CES 2019)	en	quasi-doublon	54	0,21	0,25	0,31	0,24	0,77
Meilleur parti : économie (CES 2019 tél.)	en	proche	29	0,30	0,30	0,36	0,28	0,59
Aide médicale à mourir et avortement (CES 2021)	en	loin	43	0,13	0,15	0,23	0,33	0,58
Signes religieux des enseignants (EEQ 2018)	fr	isolée	8	0,09	0,16	0,26	0,15	0,39
Impact économique des immigrants (CES 2019 tél.)	en	modérée	15	0,23	0,27	0,22	0,21	0,55
Pratique religieuse et société (EEQ 2008)	fr	quasi-doublon	10	0,28	0,36	0,35	0,36	0,67

Questions groupées par thème (identité et fédéralisme, partis et vote, valeurs sociales). Proximité : distance sémantique entre la question et la plus proche question d'entraînement. Les écarts varient beaucoup d'une question à l'autre, sans tendance nette selon la proximité ou la langue (modèle entraîné : 0,220 en français, 0,219 en anglais).

B. Sensibilité : sous-groupes d'au moins 30 répondants

Condition	Variation totale	IC 95 %	Écart au plancher
Humain	0,153	[0,124 ; 0,185]	—
Entraîné	0,205	[0,171 ; 0,245]	+0,052 [0,031 ; 0,070]
Entraîné + indices	0,236	[0,178 ; 0,295]	+0,082 [0,039 ; 0,129]
Indices retirés	0,240	[0,189 ; 0,288]	+0,087 [0,048 ; 0,132]
Non entraîné	0,566	[0,479 ; 0,642]	+0,412 [0,346 ; 0,483]

144 sous-groupes, 11 questions : « Impact économique des immigrants » n'a aucun sous-groupe d'au moins 30

répondants d'évaluation. Cette sensibilité est donc descriptive et ne remplace pas l'analyse principale sur 12 questions.

C. Détail par température

Part de l'option la plus fréquente (vrais répondants : 50 %)

Condition	T = 0,3	T = 0,7	T = 1,0	T = 1,3
Non entraîné	98 %	95 %	93 %	91 %
Entraîné	81 %	60 %	51 %	44 %
Entraîné + indices	78 %	56 %	47 %	42 %
<i>Indices retirés</i>	66 %	50 %	43 %	39 %

Contrastes appariés (différence de variation totale, IC 95 % ; négatif = premier meilleur)

Contraste	T = 0,3	T = 0,7	T = 1,0	T = 1,3
Entraîné – Non entraîné	-0,22 [-0,27 ; -0,17]	-0,33 [-0,35 ; -0,25]	-0,33 [-0,35 ; -0,23]	-0,31 [-0,34 ; -0,20]
Entraîné + indices – Entraîné	+0,05 [-0,01 ; 0,11]	+0,04 [0,00 ; 0,08]	+0,03 [-0,00 ; 0,06]	+0,03 [-0,00 ; 0,05]
Entraîné + indices – Indices retirés	+0,05 [-0,02 ; 0,12]	+0,02 [-0,03 ; 0,06]	+0,00 [-0,04 ; 0,04]	+0,00 [-0,03 ; 0,03]
Fuite – Entraîné + indices	-0,01 [-0,03 ; 0,00]	-0,02 [-0,03 ; 0,00]	-0,01 [-0,02 ; 0,01]	-0,01 [-0,03 ; 0,00]

Réponses invalides (réponse qui ne correspond exactement à aucune option). Aucun tirage n'est perdu en silence : les erreurs d'API sont réessayées jusqu'à obtenir une réponse, sinon le run s'arrête.

Condition	T = 0,3	T = 0,7	T = 1,0	T = 1,3
Non entraîné	0,0 %	0,0 %	0,0 %	0,2 %
Entraîné	0,0 %	0,0 %	0,4 %	4,6 %
Entraîné + indices	0,0 %	0,0 %	0,5 %	5,2 %
<i>Indices retirés</i>	0,0 %	0,0 %	0,4 %	4,8 %

D. Aplatissement des différences entre sous-groupes

Rapport entre la variance des distributions prédites d'un sous-groupe à l'autre et la variance observée (1 = le modèle différencie les groupes autant que la réalité ; 0 = même réponse pour tous). Médiane sur les options, température 1,0, sous-groupes d'au moins 100 répondants seulement (3 questions).

Non entraîné	Entraîné	Entraîné + indices	<i>Indices retirés</i>	<i>Fuite</i>
0,00	0,57	1,09	0,55	1,06

Le modèle non entraîné donne la même distribution à tous les groupes. Sans indices, les modèles entraînés compressent les écarts entre groupes de moitié environ ; les indices les rétablissent. À prendre avec prudence : 3 questions seulement.

E. Détails techniques

- **Entraînement** : Llama-3.3-70B-Instruct sur Azure AI Foundry, 1 époque, lots de 64, multiplicateur de taux d'apprentissage 1, graine 20260924. La cible est le texte exact de l'option choisie, pour permettre le transfert vers des questions dont les codes diffèrent.
- **Langue** : chaque répondant voit la question, les indices et son profil dans sa langue de passation ; une question sans version complète dans cette langue est exclue plutôt que traduite.
- **Correspondance avec les fichiers d'analyse** : Non entraîné = R ; Entraîné = A (modèle C0) ; Entraîné + indices = BS, Indices retirés = B0, Fuite = B (modèle C1).