

Estimer l’opinion d’un sous-groupe sur une question inédite

Premiers résultats du pilote (Llama 3.3 70B fine-tuné, 12 items)

Hubert Cadieux

Septembre 2026

En bref

J’ai fine-tuné Llama 3.3 70B sur des réponses individuelles de 17 sondages québécois et canadiens, puis je lui ai demandé de reproduire la **distribution des réponses d’un sous-groupe** (âge $\times$ genre $\times$ scolarité) à des questions qu’il n’a jamais vues. Le pilote porte sur 12 questions et 275 sous-groupes.

- **Le fine-tuning fonctionne.** Il divise par 2,5 la distance aux vrais répondants par rapport au modèle de base (variation totale 0,22 contre 0,55) et comble environ 90 % de l’écart entre le modèle de base et un plancher « humain » (deux échantillons de vraies personnes : 0,19).
- **Ajouter de l’information sur le sous-groupe n’aide pas.** Donner au modèle les réponses du sous-groupe à des questions voisines ne fait pas mieux que le modèle le plus simple.
- **La température compte pour le modèle fine-tuné, presque pas pour le modèle de base,** comme dans ta note : forte baisse de 0,3 à 0,7, plateau ensuite.

Des runs deux fois et demie plus longs (20 000 exemples) sont en cours.

1. Ce que j’ai fait

La question

Peut-on estimer comment un sous-groupe répondrait à une **nouvelle** question de sondage, sans l’avoir jamais posée? L’unité évaluée n’est pas la personne mais la distribution d’un groupe : par exemple, la répartition des réponses des femmes de 25 à 34 ans titulaires d’un bac à une question sur la souveraineté.

Les données

Sondages	17 sondages québécois et canadiens, 1998–2025, en français et en anglais
Répondants	108 199
Questions	1 778 au catalogue, dont 1 633 utilisables comme cibles d’opinion
Test	60 questions gelées avant tout entraînement ; ce pilote en utilise 12
Unités évaluées	275 couples question $\times$ cellule

Une **cellule** est une combinaison âge $\times$ genre $\times$ scolarité (218 couples) ou âge $\times$ genre quand les effectifs ne permettent pas plus fin (57 couples). Les 12 questions pilotes couvrent trois thèmes (identité et fédéralisme, partis et vote, valeurs sociales), les deux langues, et des questions plus ou moins proches de celles vues à l’entraînement.

Le partage des répondants

Le partage est fait **par répondant**, dans chaque sondage. 78 055 répondants servent à l’entraînement ; 30 144 n’y participent jamais. Ces derniers sont coupés en deux moitiés gelées : 14 947 répondants de **contexte** (qui peuvent nourrir le prompt) et 15 197 répondants d’évaluation (la vérité à reproduire, jamais montrée au modèle).

Deux modèles fine-tunés, cinq façons de les interroger

Les deux modèles sont entraînés sur les **mêmes 8 000 couples** répondant-question, avec la réponse réelle du répondant comme cible (1 époque, Azure AI Foundry). Seul le prompt d’entraînement change :


- **FT-Profil** voit le profil sociodémographique et la question ;
- **FT-Voisins** voit en plus les réponses du même répondant à jusqu’à six questions voisines.

À l’inférence, chaque condition reçoit le profil de la cellule, la question et ses options, puis répond 100 fois par cellule à quatre températures (0,3 ; 0,7 ; 1,0 ; 1,3).

Condition	Modèle	Contexte ajouté dans le prompt
Base	Llama 3.3 70B, sans fine-tuning	aucun
Profil	FT-Profil	aucun
Voisins	FT-Voisins	aucun
Voisins+Cellule	FT-Voisins	distributions de la cellule sur jusqu’à 6 questions voisines, calculées sur les répondants de contexte
Fuite	FT-Voisins	mêmes distributions, calculées sur tous les répondants gelés (évaluation incluse)

Le contexte ne contient jamais la question cible ni sa distribution. **Fuite** n’est pas une méthode : c’est un contrôle qui mesure si réutiliser les répondants d’évaluation dans le contexte gonfle les résultats.

Protocole expérimental



L'évaluation

Pour chaque question $\times$ cellule, les 100 réponses forment une distribution, comparée à la distribution pondérée des répondants d'évaluation par la **variation totale** ($\frac{1}{2} \sum_k |p_k - q_k|$: 0 = identique, 1 = disjoint). On fait la moyenne sur les cellules de chaque question, puis sur les 12 questions. Les comparaisons entre conditions sont **appariées** sur les mêmes cellules, avec un bootstrap sur les questions. L'analyse principale est à température 1,0 ; le protocole a été fixé avant de regarder les résultats.

Plancher humain. Pour donner une échelle, on compare aussi, cellule par cellule, la distribution des répondants de contexte à celle des répondants d'évaluation. C'est la distance entre deux échantillons de vraies personnes du même profil, soit le bruit d'échantillonnage pur. Les cellules étant petites (environ 40 répondants par moitié), ce plancher est élevé. Il est aussi un peu pessimiste : il additionne le bruit de deux échantillons, alors qu'un modèle parfait ne subirait que celui de l'échantillon d'évaluation.

Nos chiffres ne se comparent pas directement aux tiens : métrique différente (variation totale plutôt que KL) et évaluation par cellule plutôt que sur la distribution nationale.

2. Résultats

Le fine-tuning s'approche du plancher humain

Condition	Variation totale	IC 95 %	Écart au plancher humain
Humain (plancher)	0,186	[0,153 ; 0,222]	—
Profil	0,219	[0,186 ; 0,257]	+0,033 [0,014 ; 0,051]
Voisins	0,242	[0,203 ; 0,283]	+0,056 [0,014 ; 0,100]
Voisins+Cellule	0,246	[0,202 ; 0,288]	+0,059 [0,025 ; 0,097]
Fuite	0,240	[0,195 ; 0,290]	+0,054 [0,013 ; 0,099]
Base	0,548	[0,478 ; 0,616]	+0,362 [0,304 ; 0,430]


Température 1,0 ; 12 questions, 275 cellules ; IC par bootstrap sur les questions.

Profil comble environ 90 % de l'écart entre Base et le plancher humain : $(0,548 - 0,219) / (0,548 - 0,186)$. Il reste significativement au-dessus du plancher, et l'écart grandit sur les cellules d'au moins 30 répondants, où le plancher est moins bruité (+0,052 [0,031 ; 0,070], annexe B).

Le modèle de base échoue surtout parce qu'il **répond presque toujours la même chose** : son option la plus fréquente reçoit 93 % des tirages même à température 1,0, contre 50 % chez les vrais répondants. Profil retrouve la bonne dispersion (50,5 %). C'est plus marqué que ton bras roleplay (environ 54 % de part modale) : un 70B instruit, sans fine-tuning, s'effondre sur une réponse.

Résultats par item, température 1,0

Variation totale moyenne sur les cellules de chaque item.




Le résultat tient question par question : Profil est plus proche du plancher que de Base sur les 12 questions, et à moins de 0,04 du plancher sur 8 d'entre elles.

Le contexte du sous-groupe n'aide pas

Comparaisons appariées, température 1,0

Différence de variation totale et IC 95 % (bootstrap apparié). Négatif = premier bras meilleur.




- **Voisins+Cellule contre Voisins : +0,003 [−0,038 ; 0,040]**. Montrer au modèle comment la cellule a répondu à des questions voisines ne change rien en moyenne.
- **Voisins+Cellule contre Profil : +0,026 [−0,005 ; 0,057]**. Le montage le plus riche ne bat pas le plus simple ; la tendance est même légèrement défavorable.
- **Fuite contre Voisins+Cellule : −0,005 [−0,024 ; 0,012]**. Réutiliser les répondants d'évaluation dans le contexte ne gonfle pas les résultats : la version propre ne perd rien.

Une piste : FT-Voisins a appris à partir des réponses **individuelles** d'un répondant, mais reçoit à l'inférence des **distributions** de groupe. Ce changement de format peut l'empêcher d'exploiter le contexte. Le contexte n'est pas inutile pour autant : il rend au modèle les différences entre cellules que Profil aplatit (annexe D), sans que ça se traduise en distance moyenne.

La température : même profil que dans ta note

Distance aux vrais répondants selon la température

Variation totale moyenne, 12 items, 275 cellules. Plus bas = plus fidèle.



Les modèles fine-tunés passent de 0,37–0,42 à 0,22–0,25 entre les températures 0,3 et 1,0, puis plafonnent jusqu'à 1,3. Le modèle de base bouge peu (0,59 à 0,53). C'est le même contraste que tu observais entre fine-tune et roleplay, sur un modèle 17 fois plus gros : la température agit sur un modèle entraîné, beaucoup moins sur un modèle simplement prompté. Nous n'avons pas testé 0,0.

3. Limites et suite

- **Pilote de 12 questions.** Les 48 autres questions gelées ne sont pas encore évaluées.
- **Petites cellules.** La médiane est de 31 répondants d'évaluation par cellule ; seules 144 des 275 en ont au moins 30. Les contrastes appariés restent valides, mais les niveaux absolus sont gonflés par le bruit, d'où le plancher humain.
- **Décalage entraînement–inférence** pour FT-Voisins (réponses individuelles contre distributions), qui pourrait expliquer l'absence de gain du contexte.
- **Un seul modèle de base** (Llama 3.3 70B), une seule époque, 8 000 exemples.
- **En cours** : les mêmes deux modèles entraînés sur 20 000 exemples. Ça testera directement ta conclusion selon laquelle entraîner plus longtemps dégrade les résultats.

Annexes

A. Résultats par question (température 1,0)

Question	Lang.	Proximité	Cell.	Humain	Profil	Voisins	V.+Cell.	Base
Souveraineté, langue et culture (CES 2021)	en	quasi-doublon	43	0,13	0,16	0,25	0,13	0,63
Importance de l'ethnicité et de la langue (CES 2019)	en	loin	34	0,21	0,19	0,16	0,21	0,50
Partage des dépenses fédérales (EEQ 2012)	fr	isolée	11	0,21	0,19	0,20	0,24	0,48
Plus de pouvoirs ou indépendance (EEQ 2012)	fr	proche	11	0,17	0,21	0,26	0,18	0,38
Meilleur premier ministre (CECD 1998)	fr	loin	9	0,12	0,16	0,14	0,12	0,37
Meilleur parti : immigration (EEQ 2018)	fr	modérée	8	0,17	0,24	0,32	0,34	0,67
Parti de 2 ^e choix (CES 2019)	en	quasi-doublon	54	0,21	0,25	0,24	0,31	0,77
Meilleur parti : économie (CES 2019 tél.)	en	proche	29	0,30	0,30	0,28	0,36	0,59
Aide médicale à mourir et avortement (CES 2021)	en	loin	43	0,13	0,15	0,33	0,23	0,58
Signes religieux des enseignants (EEQ 2018)	fr	isolée	8	0,09	0,16	0,15	0,26	0,39
Impact économique des immigrants (CES 2019 tél.)	en	modérée	15	0,23	0,27	0,21	0,22	0,55
Pratique religieuse et société (EEQ 2008)	fr	quasi-doublon	10	0,28	0,36	0,36	0,35	0,67

Questions groupées par thème : identité et fédéralisme, partis et vote, valeurs sociales. Proximité : distance sémantique entre la question et la plus proche question d'entraînement. Les écarts entre conditions varient beaucoup d'une question à l'autre, mais ni la proximité ni la langue n'expliquent de tendance nette sur 12 questions (Profil : 0,220 en français, 0,219 en anglais).

B. Sensibilité : cellules d'au moins 30 répondants

Condition	Variation totale	IC 95 %	Écart au plancher
Humain	0,153	[0,124 ; 0,185]	—
Profil	0,205	[0,171 ; 0,245]	+0,052 [0,031 ; 0,070]
Voisins	0,240	[0,189 ; 0,288]	+0,087 [0,048 ; 0,132]
Voisins+Cellule	0,236	[0,178 ; 0,295]	+0,082 [0,039 ; 0,129]
Base	0,566	[0,479 ; 0,642]	+0,412 [0,346 ; 0,483]

144 cellules, 11 questions : « Impact économique des immigrants » n'a aucune cellule d'au moins 30 répondants d'évaluation. Le protocole prévoit donc cette sensibilité comme descriptive, pas comme substitut à l'analyse principale sur 12 questions.

C. Réponses invalides

Une réponse est invalide si elle ne correspond exactement à aucune option offerte. Aucun tirage n'est perdu en silence : les erreurs d'API sont réessayées jusqu'à obtenir une réponse ou arrêter le run.

Condition	T = 0,3	T = 0,7	T = 1,0	T = 1,3
Base	0,0 %	0,0 %	0,0 %	0,2 %
Profil	0,0 %	0,0 %	0,4 %	4,6 %
Voisins	0,0 %	0,0 %	0,4 %	4,8 %
Voisins+Cellule	0,0 %	0,0 %	0,5 %	5,2 %
Fuite	0,0 %	0,0 %	0,5 %	5,2 %

À 1,3, les modèles fine-tunés commencent à produire du texte hors options, ce qui plaide pour 1,0.

D. Aplatissement des différences entre cellules

Ratio entre la variance des distributions prédites d’une cellule à l’autre et la variance observée (1 = le modèle différencie les groupes autant que la réalité ; 0 = même réponse pour tous). Médiane sur les options, température 1,0, calculée seulement sur les cellules d’au moins 100 répondants (3 questions).

Base	Profil	Voisins	Voisins+Cellule	Fuite
0,00	0,57	0,55	1,09	1,06

Le modèle de base donne la même distribution à tous les groupes. Les deux modèles sans contexte compressent les écarts entre groupes de moitié environ ; le contexte de la cellule les rétablit. À prendre avec prudence : 3 questions seulement.

E. Détails techniques

- **Fine-tuning** : Llama-3.3-70B-Instruct sur Azure AI Foundry (serverless), 1 époque, lot de 64, multiplicateur de taux d’apprentissage 1, graine 20260924. La cible est le texte exact de l’option choisie (pas son code), pour que le modèle puisse transférer vers des questions inédites dont les codes diffèrent.
- **Langue** : chaque répondant voit la question, le contexte et le profil dans sa langue de passation ; une question sans version complète dans cette langue est exclue plutôt que traduite.
- **Gels** : le partage des questions et des répondants a été gelé avant le fine-tuning ; le partage contexte/évaluation et les règles d’analyse, avant de consulter les résultats.
- **Correspondance avec les fichiers** : Base = R, Profil = A (modèle C0), Voisins = B0, Voisins+Cellule = BS, Fuite = B (modèle C1).