

Améliorer l'estimation de l'opinion d'un sous-groupe

Plan du deuxième test · modèles 20k · répondants réels · modèle statistique

Hubert Cadieux · 1er octobre 2026

Document de travail. Cette note préparera le deuxième brief de résultats. Elle répondra à trois questions laissées ouvertes par le premier test : est-ce que davantage d'exemples d'entraînement améliorent les estimations, est-ce que les indices deviennent utiles lorsqu'ils sont présentés comme les réponses d'une vraie personne, et comment les modèles de langage se comparent-ils à un modèle statistique entraîné sur les mêmes données?

1. Point de départ

Le premier brief, daté du 27 septembre, établit trois résultats sur 12 questions et 275 sous-groupes :

- **Entraîné 8k** réduit fortement la distance aux vrais répondants par rapport à **Non entraîné**;
- **Entraîné avec indices 8k** ne bat ni **Entraîné 8k** ni **Indices retirés 8k**;
- une température de 1,0 donne le meilleur compromis et est retenue pour la suite.

Les modèles **Entraîné 20k** et **Entraîné avec indices 20k** ont depuis terminé leur entraînement. La prochaine étape ne répète pas le balayage de température : toutes les nouvelles inférences sont faites à température 1,0, sur les mêmes 275 couples question × sous-groupe et avec 100 réponses par couple.

2. Les trois questions du deuxième test

Est-ce que plus d'entraînement aide?

Le passage de 8 000 à 20 000 exemples est évalué séparément pour les deux entraînements :

- **Entraîné 20k** contre **Entraîné 8k**;
- **Indices retirés 20k** contre **Indices retirés 8k**.

La première comparaison mesure l'effet du volume pour le modèle qui n'a jamais reçu de réponses voisines. La seconde le mesure pour le modèle entraîné à lire les réponses voisines, mais sans lui en donner à l'inférence.

Les indices fonctionnent-ils dans le format appris?

La nouvelle condition est appelée **Entraîné avec répondants**. Chaque réponse simulée reçoit les réponses individuelles d'un répondant réel du même sous-groupe à des questions voisines, dans le format utilisé à l'entraînement. La distribution du sous-groupe émerge des réponses simulées pour plusieurs personnes plutôt que d'un résumé en pourcentages.

Cette condition est évaluée avec les modèles 8k et 20k. Les comparaisons principales sont :

- **Entraîné avec répondants 8k – Indices retirés 8k** : effet des réponses individuelles;
- **Entraîné avec répondants 8k – Entraîné avec indices 8k** : nouveau format contre pourcentages;
- **Entraîné avec répondants 8k – Entraîné 8k** : meilleur montage contre modèle simple;
- **Entraîné avec répondants 20k – Indices retirés 20k** : effet des réponses individuelles à 20k;
- **Entraîné avec répondants 20k – Entraîné 20k** : meilleur montage 20k contre modèle simple 20k;

- **Entraîné avec répondants 20k – Entraîné avec répondants 8k** : effet du volume dans le nouveau montage.

Le diagnostic prévu dans l'ADR 0005 sera d'abord calculé sur les résultats existants afin de vérifier si les pourcentages poussaient le modèle dans la bonne direction tout en exagérant les différences et en concentrant trop les réponses. Ce diagnostic ne demande aucun nouvel appel au modèle.

Les modèles de langage battent-ils le modèle statistique?

Le **modèle statistique** reçoit le profil sociodémographique, la question et ses options. Il est entraîné sur les mêmes 8 000 exemples que **Entraîné 8k** et produit directement une distribution, sans échantillonner 100 réponses. Il sera comparé au plancher humain et à toutes les conditions 8k, sans choisir après coup le modèle de langage qui lui est le plus favorable.

3. Travail restant

Quatre campagnes d'inférence

Nouvelle campagne	Modèle utilisé	Information ajoutée à l'inférence	Appels
Entraîné 20k	entraîné sans réponses voisines, 20k	aucune	27 500
Indices retirés 20k	entraîné avec réponses voisines, 20k	aucune	27 500
Entraîné avec répondants 8k	entraîné avec réponses voisines, 8k	réponses individuelles	27 500
Entraîné avec répondants 20k	entraîné avec réponses voisines, 20k	réponses individuelles	27 500
Total			110 000

Il n'est pas nécessaire de refaire **Entraîné avec indices** avec le modèle 20k pour répondre aux questions principales. La comparaison entre les pourcentages et les réponses individuelles est déjà isolée avec le modèle 8k. Une campagne 20k avec les anciens pourcentages ne serait ajoutée que pour tester explicitement une interaction entre volume d'entraînement et ancien format des indices.

Traitements sans nouvelle inférence

1. intégrer les prédictions maintenant terminées du **modèle statistique**;
2. intégrer au brief le diagnostic maintenant calculé des anciens indices;
3. intégrer les quatre nouvelles campagnes à la même analyse de variation totale, de concentration et d'aplatissement des différences entre sous-groupes;
4. produire les intervalles et contrastes appariés selon les règles déjà utilisées dans le premier brief.

4. Structure prévue du brief final

Résultats provisoires

Nouvelles campagnes complètes incluses : **Entraîné 20k**, **Indices retirés 20k**. Les intervalles et conclusions seront figés après les quatre campagnes.

Condition	Variation totale	IC 95 %	KL	Sous-groupes
Plancher humain	0,186	[0,153 ; 0,222]	—	275
Entraîné 8k	0,219	[0,219 ; 0,303]	0,207	275
Indices retirés 20k	0,222	[0,224 ; 0,304]	0,209	275
Entraîné 20k	0,224	[0,218 ; 0,314]	0,212	275
Indices retirés 8k	0,242	[0,242 ; 0,326]	0,256	275
Entraîné avec indices 8k	0,246	[0,240 ; 0,333]	0,251	275
Modèle statistique	0,281	[0,259 ; 0,366]	0,277	275
Non entraîné	0,548	[0,481 ; 0,621]	1,628	275

Contrastes préannoncés disponibles

Contraste	Différence TV	IC 95 %	Différence KL
Entraîné 8k – Modèle statistique	-0,062	[-0,088 ; -0,017]	-0,069
Entraîné 20k – Entraîné 8k	0,005	[-0,018 ; 0,031]	0,005
Entraîné 20k – Modèle statistique	-0,057	[-0,074 ; -0,017]	-0,064
Indices retirés 20k – Indices retirés 8k	-0,020	[-0,053 ; 0,009]	-0,047

En bref

Trois résultats à remplir après l'analyse : effet du passage à 20k, effet des réponses individuelles et comparaison avec le modèle statistique.

Est-ce que 20k bat 8k?

Tableau des distances moyennes, contrastes appariés et résultats question par question pour **Entraîné** et **Indices retirés**.

Est-ce que les répondants réels rendent les indices utiles?

Comparaison de **Entraîné avec répondants** avec **Indices retirés**, **Entraîné avec indices** et **Entraîné**, puis examen de la concentration et des différences entre sous-groupes.

LLM ou modèle statistique?

Comparaison des erreurs, de la calibration, du coût et de la simplicité opérationnelle. La différence entre une distribution exacte du modèle statistique et une distribution estimée à partir de 100 réponses du LLM sera indiquée explicitement.

Quel montage retenir?

Le brief se terminera par une décision avant l'évaluation des 48 questions gelées restantes : modèle retenu, format des indices retenu et pertinence ou non d'augmenter encore le volume d'entraînement.

5. Tableaux et figures à préparer

- tableau principal : plancher humain, modèle statistique et toutes les conditions 8k et 20k retenues;
- figure des contrastes appariés pour les huit comparaisons préannoncées;
- figure par question montrant l'effet de 20k et celui des répondants réels;
- tableau de concentration des réponses;
- diagnostic des anciens indices : direction, amplification et entropie;
- diagnostic d'aplatissement entre sous-groupes, recalculé pour **Entraîné avec répondants**.

6. État d'avancement

Élément	État au 1er octobre
Entraîné 20k	inférence terminée
Indices retirés 20k	inférence terminée
Entraîné avec répondants 8k	inférence en cours dans Azure
Entraîné avec répondants 20k	inférence en cours dans Azure
Modèle statistique	ajustement et prédictions terminés
Diagnostic des anciens indices	terminé; voir l'annexe A

Annexe A — Diagnostic des anciens indices en pourcentages

À température 1,0, l'ajout des indices déplace les probabilités dans la direction des écarts humains pour **47,1 % [43,4 % ; 50,7 %]** des unités question × cellule × option. La pente des écarts entre cellules est de **0,144 [0,059 ; 0,215]** pour **Entraîné avec indices**, contre **0,087 [0,033 ; 0,127]** pour **Indices retirés**. Les indices augmentent donc un peu la dispersion, mais les deux conditions demeurent très loin de reproduire toute l'ampleur des écarts humains (pente de 1).

L'entropie moyenne est de **1,188 [0,929 ; 1,460]** nat chez les répondants et de **1,268 [1,027 ; 1,506]** avec les indices. La différence de **+0,080 [0,021 ; 0,142]** indique que les réponses synthétiques sont moins concentrées, et non davantage.

En clair, les pourcentages donnés en indices font bouger le modèle, mais ils ne l'aident pas à repérer de façon fiable ce qui distingue un sous-groupe. Ses déplacements ne vont pas plus souvent dans la bonne direction que dans la mauvaise et demeurent beaucoup trop faibles. Contrairement à ce qu'on soupçonnait, le modèle ne semble pas non plus se rabattre excessivement sur la réponse majoritaire : il disperse plutôt ses réponses davantage que les vrais répondants.

Ainsi, les trois prédictions de l'hypothèse 3 de l'ADR 0005 ne sont pas vérifiées. L'échec des anciens indices ne s'explique donc pas par une lecture du groupe comme s'il s'agissait d'une seule personne typique; le format en pourcentages semble surtout fournir au modèle un signal peu exploitable.

Les calculs détaillés et le texte reproductible se trouvent dans `data/analysis/second_brief/diagnostic_anciens_indices_*`. Les intervalles à 95 % reposent sur un bootstrap apparié par question; les pentes sont calculées après centrage par question et option.