

Améliorer l'estimation de l'opinion d'un sous-groupe

Résultats saillants · décision · prochaines étapes

Hubert Cadieux · 1er octobre 2026

Conclusion. Retenir **Entraîné 8k** pour la prochaine étape. Sur les 12 questions testées, passer à 20k exemples ou ajouter les réponses de personnes réelles n'améliore pas clairement les estimations. Le modèle 8k affiche la meilleure distance moyenne, avec le montage le plus simple et le moins coûteux. Il faut maintenant confirmer ce choix sur les 48 questions gelées restantes.

1. Résultats saillants

La **variation totale** mesure l'écart entre les répartitions simulée et observée. Une valeur de 0,219 signifie qu'il faudrait, en moyenne, **réaffecter au minimum environ 22 réponses sur 100** à une autre option pour reproduire la répartition observée. Il ne s'agit pas d'un taux d'erreur individuel. La divergence KL, moins directement interprétable, est conservée comme mesure de robustesse dans les résultats détaillés.

Résultat	Ce que montrent les données	Implication
20k ne bat pas 8k	Entraîné 20k exige 22,4 réaffectations sur 100, contre 21,9 pour Entraîné 8k. L'écart est incertain : +0,5 [-1,9 ; +3,1].	Ne pas investir davantage dans le volume d'entraînement pour l'instant.
Les réponses individuelles n'ajoutent pas de gain démontré	À 20k, le modèle avec répondants et le modèle simple sont à égalité : 22,4 réaffectations sur 100 chacun. À 8k, le modèle avec répondants demeure légèrement derrière le modèle simple.	Mettre en pause les montages avec indices, plus complexes et plus coûteux.
Le LLM entraîné bat le modèle statistique	Entraîné 8k exige environ 22 réaffectations sur 100, contre 28 pour le modèle statistique : un avantage de 6 réponses sur 100 [2 ; 9].	Conserver le modèle statistique comme référence, mais pas comme méthode principale.

Le plancher humain se situe à environ **19 réaffectations sur 100**. **Entraîné 8k** n'en est séparé que par environ 3 réponses sur 100, mais ce plancher reflète lui-même le bruit de deux échantillons de répondants.

Ce qui explique l'échec des indices

Présenter les indices sous forme de réponses individuelles corrige en partie la faiblesse des anciens pourcentages, sans dépasser le modèle simple. Le diagnostic des anciens indices montre pourquoi : ils font bouger les probabilités, mais pas plus souvent dans la bonne direction que dans la mauvaise (47,1 %), et reproduisent trop peu les écarts réels entre sous-groupes. Leur signal est donc peu exploitable, plutôt que trop concentré sur une réponse dominante.

2. Décision et prochaines étapes

Montage retenu

Entraîné 8k, à température 1,0, sans indices. C'est le meilleur résultat moyen observé (0,219), avec le montage le plus simple et le moins coûteux parmi les variantes entraînées.

Priorités

1. **Évaluer Entraîné 8k sur les 48 questions gelées restantes** pour vérifier que son avantage se généralise au-delà des 12 premières questions.
2. **Terminer les diagnostics susceptibles de nuancer la décision** : résultats par question, concentration des réponses et aplatissement des différences entre sous-groupes.
3. **Ne pas lancer de nouvelle campagne 20k ou avec indices** à moins qu'un diagnostic révèle un gain ciblé sur certains types de questions ou de sous-groupes.
4. **Garder le modèle statistique dans l'évaluation finale** comme référence plus simple et sans échantillonnage, malgré sa précision moyenne inférieure.

Limite à garder en tête

Ces conclusions portent sur 12 questions et 275 couples question × sous-groupe. Les intervalles excluent un gain moyen important de plusieurs variantes, mais pas de petits effets ni des avantages ciblés. La validation sur les questions gelées doit donc précéder toute conclusion générale.

Annexe A — Résultats détaillés

Résultats disponibles

Nouvelles campagnes complètes incluses : **Entraîné 20k**, **Indices retirés 20k**, **Entraîné avec répondants 8k**, **Entraîné avec répondants 20k**. Les quatre nouvelles campagnes sont complètes.

Condition	Variation totale	IC 95 %	KL	Sous-groupes
Plancher humain	0,186	[0,153 ; 0,222]	—	275
Entraîné 8k	0,219	[0,186 ; 0,255]	0,207	275
Indices retirés 20k	0,222	[0,189 ; 0,257]	0,209	275
Entraîné avec répondants 20k	0,224	[0,192 ; 0,254]	0,206	275
Entraîné 20k	0,224	[0,181 ; 0,268]	0,212	275
Entraîné avec répondants 8k	0,226	[0,191 ; 0,259]	0,207	275
Indices retirés 8k	0,242	[0,203 ; 0,280]	0,256	275
Entraîné avec indices 8k	0,246	[0,201 ; 0,288]	0,251	275
Modèle statistique	0,281	[0,235 ; 0,330]	0,277	275
Non entraîné	0,548	[0,479 ; 0,618]	1,628	275

Contrastes préannoncés disponibles

Contraste	Différence TV	IC 95 %	Différence KL
Entraîné 8k – Modèle statistique	-0,062	[-0,089 ; -0,019]	-0,069

Contraste	Différence TV	IC 95 %	Différence KL
Entraîné 20k – Entraîné 8k	0,005	[-0,019 ; 0,031]	0,005
Entraîné 20k – Modèle statistique	-0,057	[-0,075 ; -0,018]	-0,064
Indices retirés 20k – Indices retirés 8k	-0,020	[-0,052 ; 0,010]	-0,047
Entraîné avec répondants 20k – Entraîné 20k	-0,000	[-0,033 ; 0,034]	-0,006
Entraîné avec répondants 20k – Indices retirés 20k	0,001	[-0,023 ; 0,027]	-0,003
Entraîné avec répondants 20k – Entraîné avec répondants 8k	-0,003	[-0,027 ; 0,019]	-0,001
Entraîné avec répondants 20k – Modèle statistique	-0,057	[-0,093 ; -0,005]	-0,071
Entraîné avec répondants 8k – Entraîné 8k	0,007	[-0,018 ; 0,039]	0,000
Entraîné avec répondants 8k – Indices retirés 8k	-0,016	[-0,055 ; 0,025]	-0,049
Entraîné avec répondants 8k – Entraîné avec indices 8k	-0,019	[-0,043 ; 0,008]	-0,044
Entraîné avec répondants 8k – Modèle statistique	-0,055	[-0,092 ; 0,002]	-0,069

Annexe B — Protocole en bref

- Analyse principale à température 1,0 sur 12 questions et 275 couples question × sous-groupe.
- Chaque condition LLM produit 100 réponses par couple; le modèle statistique produit directement une distribution.
- Quatre nouvelles campagnes complètes : **Entraîné 20k**, **Indices retirés 20k**, **Entraîné avec répondants 8k** et **Entraîné avec répondants 20k**, pour 110 000 appels au total.
- Le modèle statistique et **Entraîné 8k** utilisent les mêmes 8 000 exemples d'entraînement.
- Les comparaisons sont appariées et leurs intervalles à 95 % reposent sur un bootstrap par question.

Annexe C — Diagnostic des anciens indices en pourcentages

À température 1,0, l'ajout des indices déplace les probabilités dans la direction des écarts humains pour **47,1 % [43,4 % ; 50,7 %]** des unités question × cellule × option. La pente des écarts entre cellules est de **0,144 [0,059 ; 0,215]** pour **Entraîné avec indices**, contre **0,087 [0,033 ; 0,127]** pour **Indices retirés**. Les indices augmentent donc un peu la dispersion, mais les deux conditions demeurent très loin de reproduire toute l'ampleur des écarts humains (pente de 1).

L'entropie moyenne est de **1,188 [0,929 ; 1,460]** nat chez les répondants et de **1,268 [1,027 ; 1,506]** avec les indices. La différence de **+0,080 [0,021 ; 0,142]** indique que les réponses synthétiques sont moins concentrées, et non davantage.

Les trois prédictions de l'hypothèse 3 de l'ADR 0005 ne sont donc pas vérifiées. Les pourcentages font bouger le

modèle, mais ne l'aident pas à repérer de façon fiable ce qui distingue un sous-groupe. Le format semble surtout fournir un signal peu exploitable.

Les calculs détaillés et le texte reproductible se trouvent dans `data/analysis/second_brief/diagnostic_anciens_indices_*`. Les intervalles à 95 % reposent sur un bootstrap apparié par question; les pentes sont calculées après centrage par question et option.