

Peut-on faire mieux que 0,219?

48 nouvelles questions · 250 tirages

Hubert Cadieux · 29 septembre 2026

Question. Peut-on battre le résultat de **0,219** obtenu avec **Entraîné 8k**?

Réponse. Pas sur ces nouvelles questions. Le meilleur résultat est **0,260** avec **Avec répondants 20k**, contre 0,304 pour **Entraîné 8k** sur les mêmes 48 questions. Le gain est de 0,044 (IC 95 % : [0,023 ; 0,067]), mais le résultat demeure au-dessus du 0,219 obtenu sur les 12 questions initiales.

Test

Les 48 questions gelées restantes donnent **885 couples question × sous-groupe**. Chaque bras produit 250 réponses par couple, à température 1,0.

Bras	Modèle	Information ajoutée
Entraîné 8k	standard 8k	aucune
Entraîné 20k	standard 20k	aucune
Indices retirés 20k	entraîné avec réponses voisines, 20k	aucune
Avec répondants 20k	entraîné avec réponses voisines, 20k	réponses d'une personne réelle

On teste aussi, sans nouvelle inférence :

- la moyenne des quatre modèles;
- la moyenne des trois modèles sans réponses individuelles;
- une version régularisée d'**Entraîné 8k**;
- une version régularisée de la moyenne des quatre modèles.

La régularisation réduit les écarts prédits entre sous-groupes vers la moyenne de la question. La part de l'écart conservée est fixée sur les 12 questions initiales : 0,20 pour **Entraîné 8k** et 0,55 pour la moyenne des quatre modèles.

Résultats

Méthode	Variation totale	Écart avec Entraîné 8k	IC 95 %
Entraîné 8k	0,304	réf.	—
Entraîné 20k	0,285	-0,020	[-0,035 ; -0,005]
Indices retirés 20k	0,290	-0,014	[-0,038 ; 0,007]
Avec répondants 20k	0,260	-0,044	[-0,067 ; -0,023]
Moyenne sans répondants	0,280	-0,025	[-0,037 ; -0,013]
Moyenne des quatre modèles	0,269	-0,035	[-0,050 ; -0,022]

Méthode	Variation totale	Écart avec Entraîné 8k	IC 95 %
Entraîné 8k régularisé	0,301	-0,003	[-0,005 ; -0,001]
Moyenne régularisée	0,269	-0,036	[-0,050 ; -0,022]

Meilleur résultat : 0,260 avec Avec répondants 20k.

Ce qui fait une différence

- **20k contre 8k** : le passage à 20k réduit la variation totale de 0,020 ([-0,035 ; -0,005]). Le volume supplémentaire aide clairement.
- **Répondants réels, à modèle constant** : leur ajout réduit la variation totale de 0,030 par rapport à **Indices retirés 20k** ([-0,046 ; -0,015]). C'est l'amélioration la plus convaincante.
- **Combinaison des modèles** : les deux moyennes améliorent **Entraîné 8k**, mais la moyenne des quatre (0,269) reste derrière **Avec répondants 20k** (0,260). La différence entre les deux n'est toutefois pas nette ([-0,021 ; 0,002] pour Avec répondants 20k moins la moyenne).
- **Régularisation des écarts entre sous-groupes** : elle aide légèrement **Entraîné 8k** (-0,003), mais ne change pratiquement pas la moyenne des quatre (-0,000; [-0,001 ; 0,001]).

Où est-ce que ça marche?

On retient d'abord la meilleure méthode sur l'ensemble des 48 questions. On vérifie ensuite si son gain tient selon le thème et selon la proximité de la question avec le corpus d'entraînement. On ne choisit pas une méthode différente après coup pour chaque catégorie.

Thème	Questions	Entraîné 8k	Méthode retenue	Écart
Partis et vote	9	0,422	0,327	-0,095
Démocratie et engagement	9	0,276	0,238	-0,037
Valeurs sociales	8	0,259	0,272	+0,013
Santé	6	0,239	0,219	-0,020
État et économie	6	0,301	0,269	-0,032
Économie perçue	5	0,277	0,204	-0,073
Identité et fédéralisme	5	0,328	0,252	-0,075

Proximité avec l'entraînement	Questions	Entraîné 8k	Méthode retenue	Écart
Isolée (< 0,70)	10	0,322	0,262	-0,060
Loin (0,70-0,775)	9	0,300	0,263	-0,038
Modérée (0,775-0,85)	10	0,296	0,255	-0,040
Proche (0,85-0,95)	10	0,329	0,288	-0,042
Quasi-doublon (≥ 0,95)	9	0,272	0,230	-0,042

Lecture : le gain demeure dans les cinq niveaux de proximité et il est même le plus grand sur les questions isolées. Il n'augmente donc pas simplement avec la proximité du corpus. Le passage de 8k à 20k aide lui aussi surtout les questions isolées; son avantage est presque nul dans la catégorie « loin ». **Avec répondants 20k** améliore six thèmes sur sept, mais recule de 0,013 sur les valeurs sociales.

Décision

Méthode retenue : Avec répondants 20k.

Gain par rapport à Entraîné 8k : 0,044, soit une réduction de 14,6 % de la variation totale ([0,023 ; 0,067]).

Pourquoi : c'est la plus faible variation totale observée; son avantage est net à la fois contre **Entraîné 8k** et contre le même modèle 20k privé des réponses individuelles. Il améliore aussi le résultat dans toutes les catégories de proximité. Sa faiblesse sur les valeurs sociales et l'absence d'avantage clair sur la moyenne des quatre modèles doivent néanmoins rester visibles.

Les contrastes sont appariés sur les mêmes questions et sous-groupes. Les intervalles à 95 % sont obtenus par bootstrap des 48 questions. Chaque question reçoit le même poids après calcul de la moyenne de ses sous-groupes. La divergence KL, qui mène aux mêmes conclusions générales, est conservée dans les résultats détaillés.

Prochaines étapes

- **Mesurer la marge restante :** calculer le plancher humain sur les 48 questions et séparer l'erreur sur la distribution générale de chaque question de celle sur les écarts entre sous-groupes.
- **Investir dans les répondants réels :** entraîner à plus grande échelle, avec plusieurs réponses d'une même personne et exactement le même format de contexte à l'entraînement et à l'inférence.
- **Cibler les échecs :** comprendre pourquoi les réponses individuelles nuisent aux valeurs sociales et tester un repli préspecifié vers le modèle simple lorsque le contexte est peu fiable.
- **Améliorer la calibration :** tester une combinaison où le LLM estime les différences entre profils et un modèle statistique stabilise la distribution générale de la question.
- **Repartir sur un test aveugle :** geler de nouvelles questions, inclure davantage de thèmes difficiles et privilégier des sous-groupes d'évaluation plus grands.
- **Ne pas prioriser :** davantage de températures ou de tirages, les anciens indices en pourcentages, une régularisation plus complexe ou des ensembles génériques.